

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC ỨNG DỤNG



PHƯƠNG PHÁP SỐ

BÁO CÁO BÀI TẬP LỚN

NỘI SUY RBF CHO DỮ LIỆU KHÔNG GIAN

GVHD: TS. Đặng Văn Vinh
Danh sách nhóm

Phân công	Họ và tên	MSSV
Cơ sở lý thuyết	Nguyễn Đình Thái	2413130
Bài toán nội suy không gian	Nguyễn Quang Tùng	2413876
Proofread, powerpoint	Nguyễn Minh Trí	2413637
Các bài toán thực hành	Nguyễn Phúc Thịnh	2413326
Các bài toán thực hành	Lê Kiều Hân	2410941
Proofread, Thuyết trình	Nguyễn Đức Anh Tuấn	2413788
Bài toán nội suy không gian	Nguyễn Bùi Gia Tiến	2413479

THÀNH PHỐ HỒ CHÍ MINH, THÁNG 12 2025

Mục lục

1	Mở đầu	6
2	Cơ sở lý thuyết	7
2.1	Hàm bán kính (Radial Function)	7
2.2	Nội suy hàm bán kính cơ sở	7
2.2.1	Đặt vấn đề và mục tiêu	7
2.2.2	Hàm nội suy RBF	7
2.2.3	Phân tích ảnh hưởng của hàm nhân và tham số hình dáng	8
2.2.4	Quy trình giải và ví dụ minh họa	14
2.3	Các tiêu chuẩn đánh giá sai số	17
3	Nội suy bản đồ nhiệt, dự đoán nhiệt độ	18
3.1	Mô tả bài toán và Dữ liệu	18
3.1.1	Phát biểu bài toán	18
3.1.2	Xử lý dữ liệu đầu vào	18
3.2	Các bước giải bài toán	19
3.2.1	Bước 1: Phân chia tập dữ liệu (Data Splitting)	19
3.2.2	Bước 2: Tối ưu hóa mô hình RBF	19
3.2.3	Bước 3: Giải hệ phương trình và Xây dựng hàm nội suy	19
3.2.4	Bước 4: Tạo lưới và Trực quan hóa kết quả	20
3.3	Kết quả, đánh giá và so sánh	20
3.3.1	Đánh giá trực quan (Qualitative Evaluation)	20
3.3.2	Đánh giá định lượng sai số (Quantitative Evaluation)	22
3.3.3	Tổng hợp so sánh	23
3.3.4	Kết luận	24
4	Mở rộng: Phóng to/ thu nhỏ hình ảnh	25
4.1	Cơ sở lý thuyết và phương pháp tiếp cận	25
4.1.1	Phương pháp đối chứng: Bicubic Spline (Nội suy cục bộ)	25
4.1.2	Phương pháp đề xuất: RBF Thin Plate Spline (Nội suy toàn cục)	25
4.2	Quy trình thực hiện thuật toán	26
4.2.1	Bước 1: Chuyển đổi không gian (Mapping)	26
4.2.2	Bước 2: Phân tách kênh màu (Channel Splitting)	26
4.2.3	Bước 3: Huấn luyện mô hình RBF	26



4.2.4	Bước 4: Tái tạo và Tổng hợp ảnh (Reconstruction)	27
4.3	Thực nghiệm và Đánh giá kết quả	27
4.3.1	Đánh giá chất lượng hình ảnh (Image Quality)	27
4.3.2	Phân tích hiệu năng tính toán (Computational Complexity)	28
4.4	Kết luận phần mở rộng	28
5	Lời kết	30
6	Tài liệu tham khảo	32
	Phụ lục: Mã nguồn và Dữ liệu	34



Danh sách hình vẽ

2.1	Nhân Gauss và nhân Multiquadric	9
2.2	Đồ thị so sánh nhân Gauss và nhân TPS	10
2.3	Đồ thị số điều kiện theo tham số hình dạng cho ma trận nội suy hàm cơ sở bán kính 15x15 sử dụng Gaussian	10
2.4	Nội suy RBF nhân Gauss	11
2.5	Đồ thị sai số	11
2.6	Nội suy RBF nhân Gauss với ϵ nhỏ	12
2.7	Sai số khi ϵ nhỏ	12
2.8	Nội suy RBF nhân Gauss với ϵ lớn	13
2.9	Sai số khi ϵ lớn	13
2.10	Minh họa kết quả	16
3.1	Kết quả nội suy với nhân Thin Plate Spline (TPS)	21
3.2	Kết quả nội suy với nhân Gaussian.	21
3.3	Kết quả nội suy với nhân Multiquadric.	22
4.1	Kết quả tái tạo ảnh: Bicubic Spline (Trái) và RBF Thin Plate Spline (Phải).	27

Danh sách bảng

3.1	Kết quả đánh giá sai số của mô hình TPS trên tập kiểm tra	22
3.2	So sánh đặc tính thực nghiệm của các hàm nhân RBF	23
4.1	So sánh độ phức tạp thuật toán	28

Listings

1 Mở đầu

Chúng ta đang sống trong kỷ nguyên mà dữ liệu số hóa đóng vai trò quyết định trong việc mô phỏng và dự báo thế giới thực. Từ việc vẽ nên các bản đồ địa hình 3D chi tiết trong hệ thống thông tin địa lý (GIS) đến việc khôi phục các vùng ảnh bị khuyết trong xử lý ảnh y khoa, tất cả đều quy về một bài toán cốt lõi của Phương pháp số: Làm thế nào để tìm ra giá trị tại các vị trí chưa biết dựa trên những dữ liệu điểm rải rác đã có?

Trong lĩnh vực Toán học tính toán và Khoa học dữ liệu hiện đại, bài toán tái tạo bề mặt từ tập dữ liệu rời rạc luôn là thách thức trọng yếu. Đặc biệt đối với dữ liệu không gian. Những phương pháp nội suy truyền thống dựa trên lưới (mesh - based) hay đa thức cục bộ thường bộc lộ nhiều hạn chế khi đối mặt với loại dữ liệu này, dẫn đến sai số lớn hoặc sự mất ổn định trong tính toán.

Trước nhu cầu cấp thiết về một công cụ xấp xỉ mạnh mẽ hơn, linh hoạt hơn, phương pháp Nội suy hàm bán kính cơ sở (RBF) đã ra đời và chứng minh vị thế vượt trội của mình. Không phụ thuộc vào lưới và chỉ dựa vào khoảng cách Euclide giữa các điểm, RBF cho phép xây dựng các mô hình nội suy với độ chính xác cao, đảm bảo tính trơn (smoothness) của bề mặt ngay cả trong không gian nhiều chiều phức tạp. Trong khuôn khổ bài báo cáo này, chúng em sẽ đi sâu tìm hiểu nguyên lý hoạt động của nội suy RBF, so sánh hiệu quả của nó với các phương pháp khác và triển khai ứng dụng cụ thể trên tập dữ liệu không gian thực tế.

2 Cơ sở lý thuyết

2.1 Hàm bán kính (Radial Function)

Một hàm $\varphi : \mathbb{R}^n \rightarrow \mathbb{R}$ được gọi là hàm bán kính (radial function) nếu giá trị của nó tại một điểm x chỉ phụ thuộc vào khoảng cách từ điểm đó đến một tâm c xác định, tức là $\varphi(x) = \phi(\|x - c\|)$. Trong báo cáo này, khoảng cách giữa hai điểm $x, c \in \mathbb{R}^n$ được xác định bằng chuẩn Euclid (Euclidean norm):

$$r = \|x - c\|_2 = \sqrt{\sum_{i=1}^n (x^{(i)} - c^{(i)})^2}$$

Khi đó, hàm bán kính có dạng tổng quát: $\phi(r) : \mathbb{R}_{\geq 0} \rightarrow \mathbb{R}$. Nếu một hàm bán kính được sử dụng làm cơ sở (basis) cho việc xấp xỉ hàm số hoặc không gian vector, ta gọi nó là Hàm cơ sở bán kính (Radial Basis Function - RBF).

2.2 Nội suy hàm bán kính cơ sở

2.2.1 Đặt vấn đề và mục tiêu

Bài toán: Cho tập dữ liệu mẫu gồm N điểm rời rạc $X = \{x_1, x_2, \dots, x_N\} \subset \mathbb{R}^n$ và các giá trị hàm mục tiêu tương ứng $Y = \{f(x_1), f(x_2), \dots, f(x_N)\}$.

Mục tiêu: Tìm một hàm nội suy $F(x)$ xấp xỉ hàm $f(x)$ sao cho hàm $F(x)$ đi qua tất cả các điểm dữ liệu đã cho:

$$F(x_i) \approx f(x_i), \quad \forall i = 1, \dots, N$$

Phương pháp nội suy RBF giải quyết bài toán này bằng cách xây dựng $F(x)$ dưới dạng tổ hợp tuyến tính của các hàm bán kính đặt tại các tâm chính là các điểm dữ liệu.

2.2.2 Hàm nội suy RBF

Hàm nội suy RBF cơ bản có dạng:

$$F(x) = \sum_{j=1}^N \lambda_j \phi(|x - x_j|_2) \quad (2.1)$$

Trong đó:

- x_j : Các điểm dữ liệu đóng vai trò là tâm của hàm cơ sở.
- ϕ : Hàm nhân (kernel) bán kính được chọn (ví dụ: Gauss, Multiquadric...).
- λ_j : Các trọng số cần tìm.

Áp dụng điều kiện nội suy $F(x_i) = f(x_i)$ cho toàn bộ N điểm, ta thu được hệ phương trình tuyến tính:

$$\Phi\Lambda = Y \quad (2.2)$$

Với Φ là Ma trận nội suy (Interpolation Matrix) có kích thước $N \times N$, phần tử $\Phi_{ij} = \phi(\|x_i - x_j\|_2)$.

Tính khả nghịch của ma trận Φ : Theo định lý Micchelli, nếu các điểm dữ liệu x_i phân biệt và hàm ϕ được chọn là xác định dương (positive definite) (ví dụ: hàm Gauss, Inverse Multiquadric), thì ma trận Φ luôn khả nghịch. Hệ phương trình (2.2) có nghiệm duy nhất Λ .

Mở rộng: RBF với đa thức phụ trợ. Đối với một số lớp hàm nhân chỉ xác định dương có điều kiện (như Thin Plate Spline: $\phi(r) = r^2 \ln r$), để đảm bảo tính khả nghịch và độ chính xác, hàm nội suy cần được cộng thêm một đa thức bậc m :

$$F(x) = \sum_{i=1}^N \lambda_i \phi(\|x - x_i\|_2) + \sum_{k=1}^{\hat{m}} \gamma_k p_k(x) \quad (2.3)$$

Trong đó, $\{p_k\}$ là cơ sở của không gian đa thức bậc m . Để giải hệ này, ta cần thêm các ràng buộc trực giao: $\sum_{i=1}^N \lambda_i p_k(x_i) = 0$. Khi đó, hệ phương trình mở rộng có dạng khối:

$$\begin{bmatrix} \Phi & P \\ P^T & 0 \end{bmatrix} \begin{bmatrix} \Lambda \\ \Gamma \end{bmatrix} = \begin{bmatrix} Y \\ 0 \end{bmatrix}$$

Hệ này đảm bảo có nghiệm duy nhất nếu tập điểm X là đơn trị (unisolvent) đối với không gian đa thức được chọn.


2.2.3 Phân tích ảnh hưởng của hàm nhân và tham số hình dáng

Hiệu quả của phương pháp nội suy RBF phụ thuộc mật thiết vào hai yếu tố: loại hàm nhân (kernel function) được sử dụng và tham số hình dáng (shape parameter) đi kèm. Việc lựa chọn không phù hợp có thể dẫn đến hiện tượng sai số lớn hoặc mất ổn định số học trong quá trình giải hệ phương trình.

a) Lựa chọn loại hàm nhân (Kernel Selection)


Các hàm nhân cơ sở được chia thành hai nhóm chính dựa trên phạm vi ảnh hưởng:

- **Nhân cục bộ (Local Kernels):** Điển hình là hàm Gauss ($e^{-(\epsilon r)^2}$) hoặc Inverse Multiquadric. Giá trị của hàm tiến về 0 khi khoảng cách $r \rightarrow \infty$. Loại nhân này phù hợp với dữ liệu có sự biến thiên cục bộ mạnh, giúp cô lập nhiều nhưng yêu cầu mật độ điểm dữ liệu đủ dày để tránh tạo ra các "hố" giá trị giữa các điểm nút.
- **Nhân toàn cục (Global Kernels):** Điển hình là Multiquadric hoặc Thin Plate Spline ($r^2 \ln r$). Giá trị hàm tăng dần theo khoảng cách. Các hàm này thường được xây dựng dựa trên các bài toán vật lý (ví dụ: cực tiểu hóa năng lượng uốn của tấm mỏng), do đó tạo ra bề mặt nội suy rất trơn (smooth), phù hợp với dữ liệu thưa thớt.



Hình 2.1: Nhân Gauss và nhân Multiquadric


Việc lựa chọn hàm nhân cần dựa trên tính chất "xác định dương" (Positive Definite) của hàm số để đảm bảo ma trận nội suy Φ luôn khả nghịch (theo định lý Micchelli), đảm bảo bài toán luôn có nghiệm duy nhất.




Hình 2.2: Đồ thị so sánh nhân Gauss và nhân TPS

b) Ảnh hưởng của tham số hình dáng (ϵ)


Tham số hình dáng ϵ (shape parameter) trong các hàm RBF (ví dụ: $\phi(r) = e^{-(\epsilon r)^2}$) quyết định độ rộng hay độ "phẳng" của hàm cơ sở. Việc chọn ϵ tuân theo **Nguyên lý Bất định (Uncertainty Principle)** giữa độ chính xác xấp xỉ và tính ổn định của hệ phương trình:



Hình 2.3: Đồ thị số điều kiện theo tham số hình dạng cho ma trận nội suy hàm cơ sở bán kính 15x15 sử dụng Gaussian



Hình 2.4: Nội suy RBF nhân Gauss




Hình 2.5: Đồ thị sai số

- **Trường hợp ϵ nhỏ (Hàm "phẳng" – Flat):** Các hàm cơ sở trải rộng và chồng lấn lên nhau.


– *Ưu điểm:* Bề mặt nội suy rất trơn, sai số lý thuyết (approximation error) thường

rất nhỏ.

- *Nhược điểm:* Các hàng trong ma trận nội suy Φ trở nên rất giống nhau (phụ thuộc tuyến tính cao). Điều này dẫn đến số điều kiện (condition number) của ma trận rất lớn ($\text{cond}(\Phi) \rightarrow \infty$), gây ra hiện tượng *Mất ổn định số học* (Numerical Instability). Khi đó, các sai số làm tròn của máy tính sẽ bị khuếch đại, khiến nghiệm tìm được sai lệch hoàn toàn.




Hình 2.6: Nội suy RBF nhân Gauss với ϵ nhỏ




Hình 2.7: Sai số khi ϵ nhỏ

- **Trường hợp ϵ lớn (Hàm "nhọn" – Peaked):** Các hàm cơ sở co cụm xung quanh tâm điểm dữ liệu.

- *Ưu điểm:* Ma trận Φ có dạng chéo trội, số điều kiện nhỏ, hệ phương trình được giải rất ổn định và nhanh chóng.
- *Nhược điểm:* Khả năng xấp xỉ kém. Bề mặt nội suy không liên kết được các điểm dữ liệu với nhau, tạo ra các "gai nhọn" (spikes) tại các điểm nút và triệt tiêu về 0 ở khoảng giữa, dẫn đến sai số nội suy lớn.



Hình 2.8: Nội suy RBF nhân Gauss với ϵ lớn



Hình 2.9: Sai số khi ϵ lớn

c) Phương pháp tối ưu hóa tham số

Để cân bằng giữa sai số xấp xỉ và độ ổn định số học, phương pháp phổ biến nhất để chọn ε tối ưu là **Kiểm chứng chéo (Cross-Validation)**, cụ thể là kỹ thuật *Leave-One-Out Cross-Validation (LOOCV)*. Quy trình thực hiện là lần lượt loại bỏ một điểm dữ liệu x_k , xây dựng hàm nội suy với các điểm còn lại và tính sai số tại điểm x_k . Giá trị ε được chọn là giá trị làm cực tiểu hóa tổng bình phương sai số của quá trình này:

$$\varepsilon_{opt} = \arg \min_{\varepsilon} \sum_{k=1}^N \left(\frac{f(x_k) - F^{[k]}(x_k)}{1 - \Phi_{kk}^{-1}} \right)^2$$

2.2.4 Quy trình giải và ví dụ minh họa

Quy trình giải thuật toán nội suy RBF:

- Bước 1: Chuẩn bị dữ liệu. Xác định tập điểm đầu vào X và giá trị Y . Chọn hàm nhân RBF phù hợp (ϕ) và tham số hình dáng (shape parameter ε) nếu có.
- Bước 2: Xây dựng ma trận hệ thống. Tính khoảng cách giữa các cặp điểm $|x_i - x_j|$. Tạo ma trận Φ (và ma trận P nếu dùng hệ mở rộng).
- Bước 3: Giải hệ phương trình. Giải hệ $\Phi\Lambda = Y$ (hoặc hệ khối mở rộng) để tìm vector trọng số Λ (và Γ).
- Bước 4: Xây dựng hàm nội suy. Thay các hệ số tìm được vào công thức (2.1) hoặc (2.3) để thu được hàm $F(x)$ hoàn chỉnh.
- Bước 5: Đánh giá. Tính giá trị $F(x)$ tại các điểm kiểm tra (test points) để đánh giá sai số.

VÍ DỤ MINH HỌA: NỘI SUY HÀM 1 BIẾN

Bài toán: Giả sử ta cần khôi phục một hàm số $f(x)$ dựa trên 3 điểm dữ liệu mẫu sau:

$$X = \{x_1 = 0; x_2 = 1; x_3 = 2\} \quad \text{và} \quad Y = \{y_1 = 0; y_2 = 1; y_3 = 0\}$$

(Dạng dữ liệu hình "quả chuông", cao ở giữa và thấp ở hai bên).

Lựa chọn mô hình:

- Hàm nhân RBF: Sử dụng hàm Gauss $\phi(r) = e^{-(\varepsilon r)^2}$.

- Tham số hình dáng: Chọn $\varepsilon = 1$ để đơn giản hóa tính toán.
- Mô hình nội suy cơ bản (không có đa thức): $F(x) = \sum_{j=1}^3 \lambda_j e^{-(x-x_j)^2}$.

Bước 1: Tính khoảng cách và xây dựng ma trận nội suy Φ

Khoảng cách giữa các cặp điểm $r_{ij} = |x_i - x_j|$:

- $r_{11} = |0 - 0| = 0 \Rightarrow \Phi_{11} = e^0 = 1$
- $r_{12} = |0 - 1| = 1 \Rightarrow \Phi_{12} = e^{-1} \approx 0.3679$
- $r_{13} = |0 - 2| = 2 \Rightarrow \Phi_{13} = e^{-4} \approx 0.0183$

Do tính đối xứng của hàm bán kính, ta có ma trận Φ (đối xứng):

$$\Phi = \begin{bmatrix} 1 & 0.3679 & 0.0183 \\ 0.3679 & 1 & 0.3679 \\ 0.0183 & 0.3679 & 1 \end{bmatrix}$$

Bước 2: Thiết lập hệ phương trình tuyến tính

Áp dụng phương trình $\Phi\Lambda = Y$:

$$\begin{bmatrix} 1 & 0.3679 & 0.0183 \\ 0.3679 & 1 & 0.3679 \\ 0.0183 & 0.3679 & 1 \end{bmatrix} \begin{bmatrix} \lambda_1 \\ \lambda_2 \\ \lambda_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$$

Bước 3: Giải hệ phương trình tìm trọng số Λ

Sử dụng phương pháp khử Gauss hoặc nghịch đảo ma trận, ta thu được nghiệm:

$$\begin{cases} \lambda_1 \approx -0.4921 \\ \lambda_2 \approx 1.3622 \\ \lambda_3 \approx -0.4921 \end{cases}$$


Nhận xét: Ta thấy λ_1 và λ_3 có giá trị âm. Điều này là để "kéo" đồ thị xuống về giá trị 0 tại $x = 0$ và $x = 2$, triệt tiêu ảnh hưởng lan truyền từ đỉnh cao tại $x = 1$.

Bước 4: Kết quả cuối cùng

Vậy, hàm nội suy RBF hoàn chỉnh cho tập dữ liệu trên là:

$$F(x) = -0.4921e^{-x^2} + 1.3622e^{-(x-1)^2} - 0.4921e^{-(x-2)^2} \quad (2.4)$$

Đây là một hàm giải tích tường minh (explicit analytical function). Với bất kỳ giá trị x bất kỳ nằm ngoài các điểm nút (ví dụ $x = 0.5$), ta chỉ cần thế vào công thức trên để tính ra giá trị dự báo $F(0.5)$.



Hình 2.10: Minh họa kết quả

Tương tự với bộ dữ liệu trên không gian 2D và không gian 3D. Kết quả nội suy của RBF 2D có dạng

$$F(x, y) = 0.0367 \cdot e^{-(x^2+y^2)} + 1.8876 \cdot e^{-((x-1)^2+y^2)} + 0.7311 \cdot e^{-(x^2+(y-1)^2)}$$

và của RBF 3D có dạng:

$$F(x, y, z) = -0.893e^{-(x^2+y^2+z^2)} + 18.876e^{-((x-1)^2+y^2+z^2)} + 29.181e^{-(x^2+(y-1)^2+(z-1)^2)}$$

Lưu ý: Các con số trong phương trình trên chỉ là lấy ngẫu nhiên để minh họa cho dạng phương trình thôi.

2.3 Các tiêu chuẩn đánh giá sai số

Để đánh giá định lượng hiệu quả của phương pháp nội suy RBF, ta sử dụng một tập dữ liệu kiểm tra (test set) gồm N_{test} điểm phân biệt với các điểm nút nội suy. Các chỉ số thống kê được sử dụng bao gồm:

- **Sai số Tuyệt đối Trung bình (MAE - Mean Absolute Error):** Đo lường mức độ sai lệch trung bình giữa giá trị nội suy và giá trị thực tế.

$$MAE = \frac{1}{N_{test}} \sum_{k=1}^{N_{test}} |F(x_k) - f(x_k)|$$

- **Căn bậc hai Sai số Bình phương Trung bình (RMSE - Root Mean Square Error):** Thước đo tiêu chuẩn thường được sử dụng trong kỹ thuật, nhạy cảm hơn với các sai số lớn (outliers) so với MAE.

$$RMSE = \sqrt{\frac{1}{N_{test}} \sum_{k=1}^{N_{test}} (F(x_k) - f(x_k))^2}$$

- **Hệ số xác định (Coefficient of Determination - R^2):** Đánh giá mức độ phù hợp của mô hình với dữ liệu. Giá trị R^2 càng gần 1, mô hình nội suy càng chính xác.

$$R^2 = 1 - \frac{\sum_{k=1}^{N_{test}} (f(x_k) - F(x_k))^2}{\sum_{k=1}^{N_{test}} (f(x_k) - \bar{f})^2}$$

Trong đó, $\bar{f}$ là giá trị trung bình của dữ liệu thực tế trên tập kiểm tra: $\bar{f} = \frac{1}{N_{test}} \sum_{k=1}^{N_{test}} f(x_k)$.

3 Nội suy bản đồ nhiệt, dự đoán nhiệt độ

3.1 Mô tả bài toán và Dữ liệu

3.1.1 Phát biểu bài toán

Bài toán đặt ra là khôi phục trường nhiệt độ liên tục $t(\mathbf{x})$ trong không gian 3 chiều $\Omega \subset \mathbb{R}^3$ dựa trên tập dữ liệu quan trắc từ các trạm khí tượng. Giả sử ta có tập dữ liệu quan sát D gồm N điểm:

$$D = \{(\mathbf{x}_i, T_i) \mid i = 1, \dots, N\}$$

Trong đó:

- $\mathbf{x}_i = (x_i, y_i, z_i)$: Vector vị trí không gian của trạm đo thứ i .
 - x_i : Kinh độ (Longitude).
 - y_i : Vĩ độ (Latitude).
 - z_i : Độ cao so với mực nước biển (Elevation).
- T_i : Giá trị nhiệt độ mục tiêu (ví dụ: T_{MAX}) tại vị trí $\mathbf{x}_i$.

Mục tiêu: Tìm hàm xấp xỉ $F(x, y, z)$ thỏa mãn điều kiện nội suy $F(x_i, y_i, z_i) \approx T_i$. Việc đưa biến độ cao z vào mô hình cho phép RBF nắm bắt được quy luật khí tượng vật lý (nhiệt độ giảm khi độ cao tăng), từ đó cho kết quả chính xác hơn so với mô hình 2D đơn thuần.

3.1.2 Xử lý dữ liệu đầu vào

Dữ liệu từ file CSV (*airTempDataTexasUS.csv*) được trích xuất 4 trường thông tin quan trọng:

1. LONGITUDE (x): Tọa độ ngang (Kinh độ).
2. LATITUDE (y): Tọa độ dọc (Vĩ độ).
3. ELEVATION (z): Cao độ địa hình (Cao độ).
4. TMAX (T): Biến mục tiêu.

Lưu ý quan trọng về chuẩn hóa (Normalization): Do đơn vị đo của các trục khác nhau (Kinh/Vĩ độ tính bằng độ, Cao độ tính bằng mét) và có biên độ chênh lệch lớn (Scale difference), việc tính khoảng cách Euclid trực tiếp sẽ gây sai số nghiêm trọng (biên độ cao sẽ lấn át biên tọa độ). Do đó, trước khi đưa vào thuật toán RBF, toàn bộ dữ liệu đầu vào (x, y, z) được chuẩn hóa về đoạn $[0, 1]$ theo công thức Min-Max Scaling:

$$x'_{new} = \frac{x - x_{min}}{x_{max} - x_{min}}$$

3.2 Các bước giải bài toán

Quy trình thực nghiệm được tiến hành theo trình tự 4 bước sau:

3.2.1 Bước 1: Phân chia tập dữ liệu (Data Splitting)

Tập dữ liệu D sau khi được làm sạch và chuẩn hóa (theo phương pháp Min-Max Scaling đã trình bày ở trên) sẽ được chia ngẫu nhiên thành hai tập con để đảm bảo tính khách quan trong kiểm thử:

- **Tập huấn luyện (Training Set - 80%):** Gồm N_{train} điểm, được sử dụng để xây dựng ma trận nội suy Φ và tìm vector trọng số Λ .
- **Tập kiểm tra (Test Set - 20%):** Gồm N_{test} điểm, không tham gia vào quá trình tính toán trọng số, được dùng để đánh giá sai số dự báo của mô hình.

3.2.2 Bước 2: Tối ưu hóa mô hình RBF

Lựa chọn hàm nhân Gaussian: $\phi(r) = e^{-(\epsilon r)^2}$. Tham số hình dáng ϵ được xác định thông qua phương pháp Kiểm chứng chéo (Cross-Validation) trên tập huấn luyện. Giá trị ϵ tối ưu là giá trị giúp cực tiểu hóa sai số trung bình trên các tập con kiểm chứng.

3.2.3 Bước 3: Giải hệ phương trình và Xây dựng hàm nội suy

Từ tập huấn luyện, ta lập hệ phương trình tuyến tính $\Phi\Lambda = T_{train}$. Với N điểm dữ liệu, ma trận Φ có kích thước $N \times N$. Giải hệ phương trình này (sử dụng phân rã Cholesky hoặc nghịch đảo ma trận giả) để thu được vector Λ . Khi đó, hàm nội suy hoàn chỉnh có dạng:

$$F(\mathbf{v}) = \sum_{j=1}^{N_{train}} \lambda_j e^{-\epsilon^2 |\mathbf{v} - \mathbf{v}_j|^2} \quad (3.1)$$

Trong đó

- $\mathbf{v} = (x, y, z)$ là vector tọa độ của điểm cần dự báo.
- $\mathbf{v}_j = (x_j, y_j, z_j)$ là vector tọa độ của điểm dữ liệu mẫu thứ j .
- $\|\mathbf{v} - \mathbf{v}_j\|$ là khoảng cách Euclid trong không gian 3 chiều, được tính bởi công thức:

$$\|\mathbf{v} - \mathbf{v}_j\| = \sqrt{(x - x_j)^2 + (y - y_j)^2 + (z - z_j)^2}$$

3.2.4 Bước 4: Tạo lưới và Trực quan hóa kết quả

Để hiển thị kết quả dưới dạng bản đồ 2D và mô hình 3D, ta thực hiện quy trình tạo lưới (grid generation):

- Tạo lưới điểm ảnh (x_{grid}, y_{grid}) phủ kín phạm vi kinh độ và vĩ độ của vùng nghiên cứu.
- Nội suy giá trị độ cao z_{grid} tại các điểm lưới này (dựa trên dữ liệu độ cao có sẵn) để tái tạo bề mặt địa hình.
- Đưa bộ ba $(x_{grid}, y_{grid}, z_{grid})$ đã chuẩn hóa vào hàm F để dự báo nhiệt độ T_{pred} .
- Ánh xạ ngược (Inverse Transform) các giá trị về đơn vị gốc để vẽ đồ thị.


3.3 Kết quả, đánh giá và so sánh

Sau khi thực hiện huấn luyện mô hình RBF trên tập dữ liệu khí tượng Texas, nhóm chúng em tiến hành thử nghiệm với 3 loại hàm nhân (kernel) khác nhau: Thin Plate Spline (TPS), Gaussian và Multiquadric. Kết quả được đánh giá trên hai phương diện: trực quan hóa (bản đồ nhiệt 2D, bề mặt 3D) và định lượng sai số.

3.3.1 Đánh giá trực quan (Qualitative Evaluation)

Dưới đây là so sánh khả năng tái tạo bề mặt nhiệt độ của ba hàm nhân:

1. Nhân Thin Plate Spline (TPS: $\phi(r) = r^2 \ln r$)




Hình 3.1: Kết quả nội suy với nhân Thin Plate Spline (TPS)

Nhận xét: Hình 3.1 thể hiện kết quả tốt nhất về mặt hình học và tính chất vật lý.

- Bề mặt nhiệt độ (hình bên phải) có độ trơn (smoothness) rất cao, trải rộng liên tục phủ kín vùng dữ liệu mà không xuất hiện các nhiễu cục bộ.
- Bản đồ nhiệt 2D (hình bên trái) cho thấy các đường đẳng nhiệt (contour lines) cong mềm mại, phản ánh đúng quy luật khuếch tán nhiệt độ trong không khí.
- *Ưu điểm:* TPS tự động tối ưu hóa độ cong bề mặt (bending energy) mà không cần người dùng phải tinh chỉnh tham số hình dáng, do đó kết quả rất ổn định.

2. Nhân Gaussian ($\phi(r) = e^{-(\epsilon r)^2}$)




Hình 3.2: Kết quả nội suy với nhân Gaussian.

Nhận xét: Quan sát Hình 3.2, ta thấy hạn chế rõ rệt của nhân Gaussian khi áp dụng cho dữ liệu thưa thớt:

- Xuất hiện hiện tượng "cô lập điểm" (island effect): Tại các trạm đo, nhiệt độ tụt xuống (hoặc vọt lên) rất nhanh tạo thành các hố sâu/đỉnh nhọn, trong khi vùng giữa các trạm thì giá trị bị "phẳng lì" (về 0 hoặc giá trị trung bình).

- *Nguyên nhân:* Do Gaussian là hàm nhân cục bộ. Khi tham số ε quá lớn (hàm cơ sở quá hẹp), các trạm đo không "nhìn thấy" nhau, dẫn đến bề mặt nội suy bị rời rạc, thiếu tính liên kết tổng thể.

3. Nhân Multiquadric ($\phi(r) = \sqrt{1 + (\varepsilon r)^2}$)



Hình 3.3: Kết quả nội suy với nhân Multiquadric.

Nhận xét: Hình 3.3 cho thấy đặc trưng của nhân Multiquadric là tạo ra các bề mặt dạng hình phễu (conical shapes).

- So với Gaussian, Multiquadric có tính toàn cục tốt hơn (bề mặt không bị đứt quãng).
- Tuy nhiên, tại các điểm cực trị (trạm đo có nhiệt độ cao nhất/thấp nhất), hàm này thường tạo ra các đỉnh rất nhọn (như hình nón úp ngược), làm cho bản đồ nhiệt trông kém tự nhiên hơn so với độ trơn mượt của TPS.

3.3.2 Đánh giá định lượng sai số (Quantitative Evaluation)

Để đảm bảo tính khách quan, mô hình được đánh giá trên tập kiểm tra (Test set - chiếm 20% dữ liệu) vốn không tham gia vào quá trình huấn luyện. Các chỉ số sai số thu được từ thực nghiệm với hàm nhân Thin Plate Spline (TPS), Gauss, Multiquadric như sau:

Bảng 3.1: Kết quả đánh giá sai số của mô hình TPS trên tập kiểm tra

Chỉ số đánh giá	TPS	Gauss	Multiquadric
MAE (Mean Absolute Error)	1.1876 °C	84.0360 °C	311.2496 °C
RMSE (Root Mean Square Error)	1.7711 °C	265.8331 °C	1060.7058 °C
R^2 Score (Hệ số xác định)	0.5851	-9346.7937	-148825.6581

Nhận xét và Phân tích: Quan sát bảng số liệu 3.1, ta nhận thấy sự chênh lệch hiệu năng cực kỳ lớn giữa các hàm nhân:

1. **Sự thất bại của Gaussian và Multiquadric:** Hai hàm nhân này cho ra sai số RMSE khổng lồ (lên tới hàng trăm, hàng ngàn độ C) và hệ số R^2 âm cực lớn.

- Điều này phản ánh hiện tượng *mất ổn định số học (numerical instability)*. Với tập dữ liệu thưa và phân bố không đều, việc tối ưu hóa tham số hình dáng ε gặp khó khăn, dẫn đến ma trận nội suy Φ bị suy biến (ill-conditioned).
- Kết quả dự báo bị dao động dữ dội (hiện tượng Runge), khiến mô hình hoàn toàn mất khả năng dự báo (tệ hơn cả việc đoán giá trị trung bình).

2. **Tính ổn định của Thin Plate Spline (TPS):** Trong bối cảnh đó, TPS là hàm nhân duy nhất hoạt động hiệu quả và cho ra kết quả có ý nghĩa vật lý.

- Sai số tuyệt đối trung bình (MAE) đạt mức **1.19 °C**, một con số chấp nhận được cho bài toán dự báo khí tượng trên diện rộng.
- Hệ số xác định $R^2 \approx 0.59$. Tuy chưa đạt mức xuất sắc (> 0.9) do hạn chế về mật độ dữ liệu đầu vào, nhưng nó cho thấy mô hình đã giải thích được gần 60% sự biến thiên của nhiệt độ thực tế.

3.3.3 Tổng hợp so sánh

Bảng số liệu dưới đây tổng hợp kết quả sai số trên tập dữ liệu thực nghiệm (được tính toán khi chạy chương trình):

Bảng 3.2: So sánh đặc tính thực nghiệm của các hàm nhân RBF

Hàm nhân	Độ trơn (Smoothness)	Tham số ε	Đánh giá
Thin Plate Spline	Rất cao (Tốt nhất)	Không cần	Lựa chọn tối ưu, bề mặt tự nhiên.
Gaussian	Thấp (Bị rời rạc)	Rất nhạy cảm	Kém hiệu quả với dữ liệu thưa.
Multiquadric	Trung bình	Cần tinh chỉnh	Tốt nhưng dễ bị nhon ở cực trị.

3.3.4 Kết luận

Từ các kết quả phân tích trên, nhóm em rút ra kết luận:

- Các hàm nhân phụ thuộc vào tham số hình dáng (Gaussian, Multiquadric) tỏ ra không phù hợp với bộ dữ liệu khí tượng hiện tại. Chúng cực kỳ nhạy cảm và dễ dẫn đến sai số bùng nổ khi dữ liệu đầu vào thừa thớt.
- Hàm nhân **Thin Plate Spline (TPS)** đã chứng minh được tính ưu việt về sự ổn định (robustness). Mặc dù độ chính xác dự báo chỉ ở mức trung bình khá ($R^2 \approx 0.59$), nhưng đây là phương pháp duy nhất tạo ra được bề mặt nhiệt độ trơn tru, có ý nghĩa và không bị phá vỡ cấu trúc toán học.
- *Hướng phát triển*: Để nâng cao hệ số R^2 cho mô hình TPS, cần bổ sung thêm mật độ trạm quan trắc hoặc đưa thêm các biến phụ trợ (như độ ẩm, hướng gió) vào mô hình trong tương lai.

4 Mở rộng: Phóng to/ thu nhỏ hình ảnh

Sau khi đã chứng minh hiệu quả của RBF trên dữ liệu phân bố ngẫu nhiên (dữ liệu khí tượng), phần này sẽ mở rộng ứng dụng của thuật toán sang miền dữ liệu có cấu trúc lưới đều (grid data), cụ thể là bài toán Tái tạo ảnh độ phân giải cao (Image Super-resolution). Mục tiêu là so sánh trực tiếp hiệu năng giữa phương pháp nội suy toàn cục (RBF) và phương pháp nội suy cục bộ truyền thống (Bicubic Spline).

4.1 Cơ sở lý thuyết và phương pháp tiếp cận

Bài toán đặt ra là phóng to một bức ảnh kích thước nhỏ $N_1 \times N_2$ lên kích thước lớn $M_1 \times M_2$ ($M > N$) mà vẫn giữ được độ sắc nét và chi tiết.

4.1.1 Phương pháp đối chứng: Bicubic Spline (Nội suy cục bộ)

Bicubic Spline là tiêu chuẩn công nghiệp trong xử lý ảnh.

- **Nguyên lý:** Giá trị của một điểm ảnh mới được tính dựa trên đa thức bậc 3 của 16 điểm lân cận gần nhất (4×4).
- **Đặc điểm toán học:** Đảm bảo tính liên tục C^1 (liên tục đạo hàm bậc 1) tại các biên lưới.
- **Ưu điểm:** Tốc độ tính toán cực nhanh ($O(1)$ cho mỗi pixel) nhờ tính chất cục bộ và khả năng tích chập (convolution).

4.1.2 Phương pháp đề xuất: RBF Thin Plate Spline (Nội suy toàn cục)

Trong cách tiếp cận này, ta coi cường độ sáng của mỗi kênh màu (R, G, B) là một "độ cao" z trên mặt phẳng tọa độ (x, y) .

- **Nguyên lý:** Xây dựng một hàm mặt cong liên tục $F(x, y)$ đi qua tất cả các điểm ảnh gốc sử dụng nhân Thin Plate Spline: $\phi(r) = r^2 \ln r$.
- **Đặc điểm toán học:** Hàm TPS cực tiểu hóa năng lượng uốn (bending energy) trên toàn bộ bức ảnh:

$$E[F] = \iint_{\mathbb{R}^2} \left(\left(\frac{\partial^2 F}{\partial x^2} \right)^2 + 2 \left(\frac{\partial^2 F}{\partial x \partial y} \right)^2 + \left(\frac{\partial^2 F}{\partial y^2} \right)^2 \right) dx dy \rightarrow \min$$

- **Kỳ vọng:** Nhờ tính chất toàn cục, RBF có khả năng tái tạo các cạnh (edges) và cấu trúc hình học tốt hơn, tránh hiện tượng răng cưa hoặc mờ nhòe cục bộ.

4.2 Quy trình thực hiện thuật toán

Khác với dữ liệu khí tượng rời rạc, dữ liệu ảnh có cấu trúc lưới đều (grid) và bao gồm nhiều kênh màu. Quy trình áp dụng RBF để phóng to ảnh được thực hiện theo 4 bước sau:

4.2.1 Bước 1: Chuyển đổi không gian (Mapping)

Mô hình RBF hoạt động trên các điểm tọa độ thực (x, y) , trong khi ảnh kỹ thuật số được lưu trữ dưới dạng ma trận pixel rời rạc.

- **Đầu vào:** Ảnh gốc độ phân giải thấp kích thước $H \times W$.
- **Chuẩn hóa:** Mỗi pixel tại vị trí hàng i , cột j được ánh xạ sang tọa độ thực $(x_i, y_j) \in [0, 1]^2$.
- **Kết quả:** Ta thu được tập dữ liệu huấn luyện gồm $N = H \times W$ điểm, trong đó mỗi điểm có dạng $((x, y), I)$, với I là cường độ sáng.

4.2.2 Bước 2: Phân tách kênh màu (Channel Splitting)

Ảnh màu thường được biểu diễn bằng không gian màu RGB (Red-Green-Blue). Do RBF nội suy hàm vô hướng (scalar function) $F : \mathbb{R}^2 \rightarrow \mathbb{R}$, ta không thể nội suy trực tiếp vector màu 3 chiều.

- Giải pháp là tách bài toán thành 3 bài toán nội suy độc lập, tương ứng với 3 kênh R, G, và B.
- Mỗi kênh màu được xem như một mặt cong địa hình riêng biệt.

4.2.3 Bước 3: Huấn luyện mô hình RBF

Áp dụng thuật toán RBF Thin Plate Spline (TPS) cho từng kênh màu:

- Xây dựng ma trận khoảng cách giữa tất cả các điểm pixel của ảnh gốc.
- Giải hệ phương trình tuyến tính $\Phi\Lambda = I_{channel}$ để tìm vector trọng số Λ cho kênh màu đó.

- Do số lượng điểm ảnh lớn (ngay cả với ảnh nhỏ 32×32 đã có 1024 điểm), việc giải hệ phương trình chiếm phần lớn thời gian tính toán của toàn bộ quy trình.


4.2.4 Bước 4: Tái tạo và Tổng hợp ảnh (Reconstruction)

Để tạo ra ảnh đích có kích thước lớn gấp k lần ($k \times H, k \times W$):

1. Tạo lưới tọa độ điểm ảnh mới (High-resolution grid) với mật độ dày đặc hơn.
2. Sử dụng các trọng số Λ đã tìm được ở Bước 3 để tính giá trị cường độ sáng dự báo tại các điểm lưới mới này.
3. **Hậu xử lý (Post-processing):** Giá trị nội suy có thể bị vượt ra ngoài khoảng hợp lệ (undershoot < 0 hoặc overshoot > 255) do tính chất dao động của hàm Spline. Ta cần thực hiện thao tác cắt gọt (clipping) để đưa giá trị về đoạn $[0, 255]$.
4. Gộp 3 kênh màu R, G, B lại để tạo thành bức ảnh màu hoàn chỉnh.

4.3 Thực nghiệm và Đánh giá kết quả

Thử nghiệm được tiến hành trên ảnh đầu vào kích thước nhỏ (32×32 pixels) chứa các chi tiết văn bản và hình học phức tạp, yêu cầu phóng to gấp 4 lần.



Hình 4.1: Kết quả tái tạo ảnh: Bicubic Spline (Trái) và RBF Thin Plate Spline (Phải).

4.3.1 Đánh giá chất lượng hình ảnh (Image Quality)

Quan sát kết quả tại Hình 4.1, ta nhận thấy sự khác biệt rõ rệt về chất lượng thị giác:

1. **Độ sắc nét biên (Edge Sharpness):**

- *Bicubic*: Các đường biên của chữ "BK" và "TP.HCM" bị hiện tượng mờ nhòe (blurring). Do tính chất làm trơn cục bộ, Bicubic giống như áp một bộ lọc thông thấp (low-pass filter), làm mất đi các tần số cao (chi tiết sắc nét).
- *RBF-TPS*: Các nét chữ gọn gàng, tách bạch và giữ được độ tương phản cao. Hiện tượng răng cưa (aliasing) được khử triệt để nhưng không làm nhòe ảnh.

2. Tính liên tục bề mặt (Surface Continuity):

- Trên các vùng chuyển màu (gradient) của khối lập phương, RBF tạo ra sự chuyển tiếp màu sắc mượt mà tự nhiên hơn. Điều này minh chứng cho tính chất vật lý của "tấm kim loại mỏng" – luôn tìm trạng thái bề mặt trơn nhất có thể.

4.3.2 Phân tích hiệu năng tính toán (Computational Complexity)

Đây là sự đánh đổi (trade-off) lớn nhất giữa hai phương pháp:

Bảng 4.1: So sánh độ phức tạp thuật toán

Tiêu chí	Bicubic Spline	RBF (Toàn cục)
Độ phức tạp Thời gian	$O(M)$ (Rất nhanh)	$O(N^3)$ (Rất chậm)
Độ phức tạp Không gian	$O(1)$ (Lưu cục bộ)	$O(N^2)$ (Lưu ma trận Φ)
Khả năng mở rộng	Tốt (Mọi kích thước)	Kém (Chỉ ảnh nhỏ)

Phân tích hạn chế của RBF: Do RBF yêu cầu giải hệ phương trình tuyến tính liên kết tất cả các điểm ảnh đầu vào (N điểm), ma trận hệ số Φ là ma trận dày đặc (dense matrix).

- Với ảnh thử nghiệm nhỏ ($32 \times 32 = 1024$ điểm), ma trận Φ có kích thước 1024×1024 , máy tính xử lý dễ dàng.
- Tuy nhiên, với ảnh trung bình ($500 \times 500 = 250,000$ điểm), kích thước ma trận lên tới 6.25×10^{10} phần tử, yêu cầu hàng trăm GB RAM, vượt quá khả năng của máy tính cá nhân.

4.4 Kết luận phần mở rộng

- RBF Thin Plate Spline cho chất lượng tái tạo ảnh vượt trội so với Bicubic về độ sắc nét và khử nhiễu, nhờ tính chất tối ưu hóa năng lượng toàn cục.



- Tuy nhiên, chi phí tính toán khổng lồ ($O(N^3)$) khiến RBF toàn cục không khả thi cho các ứng dụng xử lý ảnh thời gian thực hoặc ảnh kích thước lớn.
- **Hướng giải quyết:** Trong thực tế, để tận dụng ưu điểm của RBF cho ảnh lớn, người ta thường sử dụng phương pháp RBF cục bộ (Moving Least Squares) hoặc RBF mạng nơ-ron (RBFN) để giảm kích thước bài toán.

5 Lời kết

Qua quá trình nghiên cứu và thực hiện đề tài "Nội suy RBF cho dữ liệu không gian", nhóm chúng em đã hệ thống hóa thành công cơ sở lý thuyết và kiểm chứng tính hiệu quả của các phương pháp nội suy trong bài toán tái tạo bề mặt từ dữ liệu rời rạc. Đề tài không chỉ dừng lại ở việc áp dụng công thức, mà còn đi sâu phân tích bản chất toán học của hai hướng tiếp cận tiêu biểu: phương pháp dựa trên lưới (Grid-based) với đại diện là Bicubic Spline và phương pháp không lưới (Mesh-free) với đại diện là Radial Basis Function (RBF). Từ kết quả thực nghiệm trên tập dữ liệu nhiệt độ và hình ảnh, nhóm rút ra những kết luận quan trọng sau:

- **Thứ nhất, về khả năng thích ứng:** Phương pháp RBF chứng minh sự vượt trội khi xử lý dữ liệu phân bố ngẫu nhiên (scattered data) - dạng dữ liệu đặc thù trong đo đạc địa lý và khí tượng. Việc sử dụng nhân *Thin Plate Spline* kết hợp với đa thức bậc thấp đã tạo ra bề mặt nội suy đảm bảo độ trơn cao (C^2), giảm thiểu các dao động giả tại vùng biên và phản ánh chính xác xu hướng biến thiên vật lý của trường nhiệt độ.
- **Thứ hai, về so sánh đối chứng:** Mặc dù nội suy Bicubic là công cụ mạnh về tốc độ nhờ cấu trúc tính toán cục bộ và tích chập, nhưng phương pháp này bộc lộ hạn chế lớn khi phụ thuộc chặt chẽ vào lưới ô vuông đều. Việc áp dụng Bicubic cho dữ liệu rải rác đòi hỏi các bước tái lấy mẫu (resampling) trung gian, gây sai số tích lũy. Ngược lại, RBF giải quyết bài toán trực tiếp trên không gian tọa độ thực, bảo toàn độ chính xác gốc của dữ liệu.

Bên cạnh những ưu điểm, nhóm cũng nhìn nhận thẳng thắn về thách thức kỹ thuật của phương pháp RBF toàn cục. Đó là độ phức tạp tính toán lớn ($O(N^3)$) và yêu cầu bộ nhớ cao để lưu trữ ma trận dày đặc (dense matrix) khi số lượng điểm dữ liệu tăng lên. Đây là bài toán đánh đổi (trade-off) giữa độ chính xác và hiệu năng mà các nghiên cứu thực tế cần cân nhắc.

Hướng phát triển: Kiến thức thu được từ đề tài này là nền tảng vững chắc để nhóm tiếp tục nghiên cứu các kỹ thuật nâng cao như:

- Áp dụng các thuật toán xấp xỉ nhanh (Fast RBF, Compactly Supported RBF) để xử lý dữ liệu quy mô lớn (Big Data).
- Mở rộng mô hình sang không gian 3D nhằm giải quyết các bài toán mô phỏng vật lý phức tạp.



- Sử dụng các hàm nhân (Kernel methods) làm tiền đề lý thuyết để tiếp cận các mô hình Học máy hiện đại như RBF Neural Networks hay Support Vector Machines (SVM).

Cuối cùng, nhóm chúng em xin gửi lời cảm ơn chân thành đến TS. Đặng Văn Vinh. Sự hướng dẫn tận tình và những định hướng tư duy khoa học của Thầy là yếu tố then chốt giúp nhóm hoàn thành tốt bài tập lớn này. Chúng em xin chân thành cảm ơn!

6 Tài liệu tham khảo

Tài liệu

- [1] TS. Đặng Văn Vinh (2022). *Giáo trình Đại Số Tuyến Tính* (Tái bản lần thứ nhất). NBX. Đại Học Quốc Gia.
- [2] Stefano De Marchi (ngày 13/2/2018) Lectures on Radial Basis Functions. University of Padua (Italy). https://www.math.unipd.it/~demarchi/RBF/LectureNotes_new.pdf, truy cập ngày 11/11/2025.
- [3] Wilna du Toit (2008). *Radial Basis Function Interpolation*. [Master's Thesis, University of Stellenbosch].
- [4] Huang, T. S., & Youn, B. J. (1981). Two-Dimensional Speech Recognition Based on Spectral Analysis. *IEEE Transactions on Acoustics, Speech, and Signal Processing*, 29(6), 1461-1467. <https://doi.org/10.1109/TASSP.1981.1163711>.
- [5] Smith, R. C. (1980). An Analysis of the Phase-Dependent Effects in the Nonlinear Wave Equation. *SIAM Journal on Applied Mathematics*, 38(1), 135-145. <https://doi.org/10.1137/0722023>.
- [6] Han, D. (2013). Comparison of commonly used image interpolation methods. In *Proceedings of the 2nd International Conference on Computer Science and Electronics Engineering (ICCSEE 2013)* (tr. 1556-1559). Atlantis Press. <https://doi.org/10.2991/iccsee.2013.391>.
- [7] Fadnavis, S. (2016). Image interpolation techniques in digital image processing: An overview. ResearchGate. https://www.researchgate.net/publication/301889708_Image_Interpolation_Techniques_in_Digital_Image_Processing_An_Overview.
- [8] Khan, M. A., & Ali, A. (2018). A comprehensive review on image interpolation techniques: From traditional to deep learning approaches. *Measurement*, 129, 120-136. <https://doi.org/10.1016/j.measurement.2018.06.005>.
- [9] Gao, S., & Gruev, V. (2011). Bilinear and bicubic interpolation methods for division of focal plane polarimeters. *Optics Express*, 19(26), 26161-26173. <https://doi.org/10.1364/OE.19.026161>.



- [10] Rowe, D. B. (2018). Bi-linear, bicubic, and in between spline interpolation. Truy cập từ https://www.mssc.mu.edu/~daniel/pubs/RoweTalkMSCS_BiCubic.pdf.
- [11] Martin Buhmann (2010). *Radial Basis Function*. http://www.scholarpedia.org/article/Radial_basis_function.
- [12] J. Liesen, M. Rozloznik, và Z. Strakos (2002). *Least squares residuals and minimal residual methods*. <https://api-depositonce.tu-berlin.de/server/api/core/bitstreams/f8c420e4-f269-4067-a83d-9be3240532a6/content>.
- [13] Youcef Saad, Martin H. Schultz (1985). *GMRES: a Generalized Minimal Residual algorithm for solving nonsymmetric linear systems*. <https://cs.yale.edu/publications/techreports/tr254.pdf>.
- [14] Smith, R. C. (1980). An Analysis of the Phase-Dependent Effects in the Nonlinear Wave Equation. SIAM Journal on Applied Mathematics, 38(1), 135–145. <https://doi.org/10.1137/0722023>.

PHỤ LỤC: MÃ NGUỒN VÀ DỮ LIỆU

Để đảm bảo tính minh bạch và khả năng tái lập kết quả (reproducibility) của đề tài, nhóm chúng em cung cấp toàn bộ mã nguồn lập trình và bộ dữ liệu thử nghiệm tại kho lưu trữ trực tuyến.

A. Kho lưu trữ trực tuyến

Giảng viên và độc giả quan tâm có thể truy cập mã nguồn đầy đủ thông qua đường dẫn hoặc mã QR dưới đây:

Google Drive Repository: [NGUỒN CODE Ở ĐÂY](#)

Hoặc có thể (*Quét mã để truy cập nhanh*)



B. Cấu trúc thư mục dự án

Dự án bao gồm các tập tin mã nguồn (Python) và dữ liệu (CSV/Image) được tổ chức như sau:

- 1. Mã nguồn xử lý chính (Source Code):
 - Nội suy dữ liệu nhiệt.py: Chương trình thực thi **Bài toán 1**. Bao gồm:
 - + Định nghĩa lớp `RBFInterpolator` và các hàm nhân (Gaussian, TPS, Multiquadric).
 - + Xử lý dữ liệu khí tượng, tính toán sai số (MAE, RMSE, R^2).
 - + Vẽ và tự động lưu các bản đồ nhiệt 2D, mô hình 3D.
 - `Resize ảnh.py`: Chương trình thực thi **Bài toán 2 (Mở rộng)**. Bao gồm:
 - + Thuật toán RBF cho dữ liệu ảnh (xử lý từng kênh màu R, G, B).
 - + Module so sánh đối chứng với Bicubic Spline.

- **2. Dữ liệu đầu vào (Input Data):**

- `airTempDataTexasUS-29-04-2025-metric.csv`: Tập dữ liệu khí tượng thực tế dùng cho Bài toán 1 (bao gồm Kinh độ, Vĩ độ, Độ cao và Nhiệt độ T_{MAX}).
- `BK.png`: Ảnh gốc độ phân giải cao dùng để tạo mẫu thử nghiệm cho Bài toán 2.

- **3. Kết quả đầu ra (Outputs):**

- `/results/`: Thư mục chứa các tệp hình ảnh kết quả (.png) được chương trình tự động xuất ra sau khi chạy (Bản đồ nhiệt, Ảnh tái tạo...).

C. Trích đoạn thuật toán cốt lõi (Core Algorithm)

Dưới đây là phần cài đặt của lớp `RBFIinterpolator`, nơi định nghĩa các công thức toán học của hàm nhân và quy trình giải hệ phương trình tuyến tính để tìm trọng số (trích xuất từ file `Nội suy dữ liệu nhiệt.py`).

```
1 class RBFIinterpolator:
2     def _kernel_func(self, r):
3         """ Định nghĩa các hàm nhân RBF (Kernel Functions) """
4         if self.kernel_name == 'thin_plate_spline':
5             # TPS:  $\phi(r) = r^2 * \ln(r)$ 
6             res = np.zeros_like(r)
7             mask = r > 0
8             res[mask] = (r[mask] ** 2) * np.log(r[mask])
9             return res
10
11         elif self.kernel_name == 'gaussian':
12             # Gaussian:  $\phi(r) = \exp(-(\epsilon * r)^2)$ 
13             return np.exp(-(self.epsilon * r) ** 2)
14
15         elif self.kernel_name == 'multiquadric':
16             # Multiquadric:  $\phi(r) = \sqrt{1 + (\epsilon * r)^2}$ 
17             return np.sqrt((self.epsilon * r) ** 2 + 1)
18
19 def fit(self, X, y):
20     """ Huan luyen mo hinh: Giai he phuong trinh  $Ax = B$  """
```

```
21  # 1. Chuẩn hóa dữ liệu về [0, 1]
22  self.x_min = np.min(X, axis=0)
23  self.x_max = np.max(X, axis=0)
24  X_norm = (X-self.x_min) / (self.x_max-self.x_min+1e-8)
25
26  # 2. Tính ma trận khoảng cách và ma trận Kernel (Phi)
27  dists = cdist(X_norm, X_norm, metric='euclidean')
28  Phi = self._kernel_func(dists)
29
30  # 3. Xây dựng ma trận mở rộng với đa thức bậc 1 (P)
31  N = X_norm.shape[0]
32  P = np.hstack([np.ones((N, 1)), X_norm]) # [1, x, y, z]
33  m = P.shape[1]
34
35  # 4. Tạo hệ phương trình khối (Block Matrix System)
36  # [ Phi  P ] [ w ] = [ y ]
37  # [ P.T  0 ] [ v ]   [ 0 ]
38  top = np.hstack([Phi, P])
39  bot = np.hstack([P.T, np.zeros((m, m))])
40  A = np.vstack([top, bot])
41  rhs = np.concatenate([y, np.zeros(m)])
42
43  # 5. Giải hệ phương trình (Sử dụng scipy.linalg)
44  coeffs = scipy.linalg.solve(A, rhs)
45  self.weights = coeffs[:N]
46  self.gamma = coeffs[N:]
```